

## Zdarzenie elementarne

Każdy możliwy wynik eksperymentu losowego nazywamy **zdarzeniem elementarnym**  $\omega$ , a zbiór wszystkich możliwych wyników eksperymentu (wszystkich zdarzeń elementarnych) nazywamy **zbiorem zdarzeń elementarnych** i oznaczamy  $\Omega$ , ( $\omega \in \Omega$ ).

## Aksjomaty prawdopodobieństwa

Dla danego zbioru zdarzeń elementarnych  $\Omega$  oraz  $\sigma$ -ciała zdarzeń losowych  $\mathcal{F}$ , **prawdopodobieństwem** nazywamy funkcję  $P: \mathcal{F} \rightarrow \mathcal{R}$  spełniającą:

1. Dla dowolnego zdarzenia losowego  $A \in \mathcal{F}$ ,  $P(A) \geq 0$ .
2.  $P(\Omega) = 1$ .
3. Dla dowolnego nieskończonego ciągu zdarzeń losowych  $A_1, A_2, \dots, \forall n \in \mathcal{N} A_n \in \mathcal{F}$ , parami rozłącznych, mamy  $P(\bigcup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} P(A_n)$ .

Dla dowolnych zdarzeń  $A, B$  mamy  $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ .

## Prawdopodobieństwo warunkowe

Prawdopodobieństwo  $A$  pod warunkiem że zaszło zdarzenie  $B$ :  $P(A|B) = \frac{P(A \cap B)}{P(B)}$ .

Jeżeli  $P(A_1 \cap \dots \cap A_n) > 0$ , to  $P(A_1 \cap \dots \cap A_n) = P(A_1) \prod_{i=2}^n P(A_i | A_1 \cap \dots \cap A_{i-1})$ .

## Prawdopodobieństwo zupełne

Ciąg zdarzeń nazywamy zupełnym, jeśli:

1.  $\bigcup_i A_i = \Omega$ ,
2.  $\forall i \neq j A_i \cap A_j = \emptyset$ ,
3.  $\forall_i P(A_i) > 0$ .

## Twierdzenie

Jeśli zdarzenia tworzą układ zupełny, to dla dowolnego zdarzenia  $B$  mamy  $P(B) = \sum_i P(B|A_i)P(A_i)$

## Reguła Bayesa

**Twierdzenie** Niech  $A_i$  tworzą układ zupełny. Wtedy dla dowolnego zdarzenia losowego  $B$ ,  $P(B) > 0$  i dowolnego  $j$  zachodzi  $P(A_j|B) = \frac{P(B|A_j)P(A_j)}{\sum_i P(B|A_i)P(A_i)}$

## Niezależność zdarzeń

**Definicja** Zdarzenia są wzajemnie niezależne gdy  $P(A \cap B) = P(A) \cdot P(B)$

Jeżeli zdarzenia  $A$  i  $B$  są niezależne, to nieza-

leżne są również zdarzenia  $A$  i  $\overline{B}$ ,  $\overline{A}$  i  $B$ ,  $\overline{A}$  i  $\overline{B}$ .

Zdarzenia są wzajemnie niezależne jeśli  $P\left(\bigcap_{j=1}^k A_{i_j}\right) = \prod_{j=1}^k P(A_{i_j})$ .

Jeśli  $A_1 \dots$  są zdarzeniami wzajemnie niezależnymi, to  $(\bigcup_{i=1}^n A_i) = 1 - \prod_{i=1}^n (1 - P(A_i))$

## Łączenie prawdopodobieństw

szeregowe:  $P(A_s) = \prod_{i=1}^n p_i$   
równoległe:  $P(A_r) = 1 - \prod_{i=1}^n (1 - p_i)$

## Dystrybuanta

$F(x) = P(X \leq x) = P(\{\omega \in \Omega : X(\omega) \leq x\})$

Własności:

$\lim_{x \rightarrow -\infty} F(x) = 0$ ,  $\lim_{x \rightarrow \infty} F(x) = 1$

niemalejąca, prawostronnie ciągła

$P(a < X \leq b) = F(b) - F(a)$

## Zmienne losowe dyskretne

$p(a) = P(X = a)$  - funkcja prawdopodobieństwa, własności:

$p(x) \geq 0$ ,  $\sum_{x \in X} p(x) = 1$

Dystrybuanta dyskretna zmiennej  $X$  o nośniku  $\chi$ :  $F(x) = \sum_{\{x_i \in \chi; x_i \leq x\}} p(x_i)$ .

Przykład:

$$F(x) = \begin{cases} 0, & x < 1 \\ 0.4, & 1 \leq x < 2 \\ 0.9, & 2 \leq x \end{cases}$$

## Zmienne losowe ciągłe

$P(X \in B) = \int_B f(x) dx$

$F(x) = \int_{-\infty}^x f(t) dt$

$f(x) = F'(x)$

$P(a \leq X \leq b) = F(b) - F(a)$

$P(X = a) = 0$  dla dowolnego  $a \in R$

Własności funkcji gęstości:

$\forall x \in R f(x) \geq 0$ ,  $\int_{-\infty}^{+\infty} f(x) dx = 1$

## Funkcje zmiennych losowych

Dyskretne:

$P(Y = y_i) = \sum_{\{x_j \in \chi: g(x_j) = y_i\}} P(X = x_j)$

Ciągłe: gęstość liniowej funkcji zm.los.

$\forall a \neq 0 b \in R f_{aX+b}(y) = \frac{1}{|a|} f_X\left(\frac{y-b}{a}\right)$

gęstość kwadratu zm.los.

$$f_{X^2}(y) = \begin{cases} 0, & x \leq 0 \\ \frac{1}{2\sqrt{y}} [f_X(\sqrt{y}) + f_X(-\sqrt{y})], & x > 0 \end{cases}$$

Jeśli  $g$  jest ściśle monotoniczna i różniczkowalna, to  $Y = g(X)$ :  $f_Y(y) = f_X(g^{-1}(y)) \cdot \frac{1}{|g'(g^{-1}(y))|}$

## Wartość oczekiwana

Dyskretne:  $E[X] = \sum_{x_i \in X} x_i \cdot P(X = x_i)$

Ciągłe:  $E[X] = \int_{-\infty}^{+\infty} x f(x) dx$

Dla typu mieszanego o  $F(x) = pF_d(x) + (1-p)F_c(x)$ ,  $E[X] = pE[X_d] + (1-p)E[X_c]$ .

Dla funkcji zmiennej losowej  $Y = g(X)$ :

$$E[g(X)] = \begin{cases} \sum_i g(x_i) P(X = x_i), & \text{jeśli } X \text{ jest zm.los. dyskretna} \\ \int_{-\infty}^{+\infty} g(x) f_X(x) dx, & \text{jeśli } X \text{ jest zm.los. ciągła} \end{cases}$$

Jeśli istnieje wartość oczekiwana  $E[X]$ , to

$E[aX + b] = aE[X] + b$

## Momenty

Momentem rzędu  $n$ -tego względem  $c \in R$  zmiennej losowej  $X$  nazywamy:  $E[(X - c)^n]$

Momenty zwykłe:  $c = 0$

Pierwszy moment:  $E[X]$

Jeśli istnieje  $n$ -ty moment zwykły, to istnieją wszystkie momenty rzędu mniejszego od  $n$

Momenty centralne:  $c = E[X]$

Wariancja:  $V(X) = \sigma_x^2 = \sigma^2 = E[(X - \mu)^2] = E[X^2] - (E[X])^2$ , gdzie  $\mu = E[X]$

$V(aX + b) = V(aX) = a^2 V(X)$

Odchylenie standardowe:  $\sigma = \sqrt{V(X)}$

Zmienna  $X$  jest standaryzowana jeśli  $E[X] = 0$  i  $V(X) = 1$

Standaryzacja:  $X^* = \frac{X - \mu}{\sigma}$

Współczynnik skośności:  $\gamma_1 = E\left[\left(\frac{X - \mu}{\sigma}\right)^3\right] = \frac{E[(X - \mu)^3]}{(E[(X - \mu)^2])^{3/2}}$

Kurtosis:  $\gamma_2 = \frac{\mu_4}{\sigma^4} - 3$

## Kwantyle, kwartyle

Kwantyl:  $\forall p \in (0,1) x_p = Q(p) = F^{-1}(p) = \inf\{x \in R : p \leq F(x)\}$

Mediana: kwantyl  $x_{0.5}$  rzędu 0.5.

Dolny kwantyl  $Q_1$  - kwantyl rzędu 0.25, górny kwantyl  $Q_3$  - kwantyl rzędu 0.75

Rozkład międzykwartylowy  $IQR = Q_3 - Q_1$

## Doświadczenie Bernoulliego

Doświadczenie kończące się sukcesem z prawdopodobieństwem  $p$  lub porażką z prawdopodobieństwem  $1-p$ .

Ciąg  $n$  doświadczeń z prawd. sukcesu  $p$  oznaczamy  $b(n, p)$ .

Prawdopodobieństwo uzyskania ciągu składającego się z  $k$  sukcesów, przy założeniu niezależności:  $p^k (1 - p)^{n-k}$ .

Prawdopodobieństwo uzyskania  $k$  sukcesów w  $n$  niezależnych doświadczeniach z  $p \in [0, 1]$ :

$b(k; n, p) = \binom{n}{k} p^k (1 - p)^{n-k}$ .

**Poisson** (fr. Ryba)

Dla  $n \geq 25$  i  $\lambda = n \cdot p \leq 10$  możemy przybliżyć rozkładem Poissona:  $b(k; n, p) \approx e^{-np} \frac{(np)^k}{k!}$ , na przykład:

$\sum_{k=0}^{14} b(k; 500, 0.02) \approx F(14; 500 \cdot 0.02)$ , gdzie  $F$  jest dystrybuantą rozkładu Ryby, dostępna w tablicach.

## Rozkłady zmiennych dyskretnych Bernoulli

1. Eksperyment składa się z  $n$  mniejszych doświadczeń, zwanych próbami, gdzie  $n$  jest ustalone i znane przed doświadczeniem.
2. Każda próba kończy się sukcesem lub porażką.
3. Próby są niezależne.

$X$  ma rozkład Bernoulliego jeśli

$$p(x) = P(X = x) = \begin{cases} 1 - p, & x = 0 \\ p, & x = 1 \end{cases}$$

$E[X] = p$ ,  $V(X) = p(1 - p)$

## Dwumianowy, czyli dalej Bernoulli

Zmienną losową  $X$  równą liczbie sukcesów w  $n$  niezależnych doświadczeniach Bernoulliego nazywamy zmienną o rozkładzie dwumianowym z param.  $(n, p)$ , oznaczamy  $X \sim b(n, p)$ .  $P(X = k) = b(k; n, p) = \binom{n}{k} p^k (1 - p)^{n-k}$   
 $E[X] = np$ ,  $V(X) = np(1 - p)$

## Hipergeometryczny

1. Losujemy ze zbioru  $N$  elementów.
2. Każdemu z  $N$  obiektów można przypisać sukces lub porażka (mamy  $M$  sukcesów).
3. Wybieramy  $n$  obiektów bez zwracania tak, że wybór każdego  $n$  elementowego podzbiotu ma to samo prawdopodobieństwo.

Liczba sukcesów  $X$  ma rozkład hipergeometryczny  $X \sim HG(n, M, N)$ ,  $P(X = x) = h(x; n, M, N) = \frac{\binom{M}{x} \binom{N-M}{n-x}}{\binom{N}{n}}$ ,  $E[X] =$

$$\frac{nM}{N}, V(X) = \left(\frac{N-n}{N-1}\right) \frac{nM}{N} \left(1 - \frac{M}{N}\right)$$

### Ujemny dwumianowy (Pascala)

1. Niezależne próby Bernoulliego. 2. Eksperyment kończy się w chwili uzyskania  $r$ -tego sukcesu,  $r$  ustalone.

$X$  - Liczba porażek do uzyskania  $r$ -tego sukcesu ma rozkład ujemny dwumianowy  $X \sim NB(r, p)$ ,  $nb(x; r, p) = \binom{x+r-1}{r-1} p^r (1-p)^x$ ,  $E[X] = \frac{r(1-p)}{p}$ ,  $V(X) = \frac{r(1-p)}{p^2}$

#### Geometryczny

$X$  równa liczbie porażek w ciągu niezależnych doświadczeń Bernoulliego, do uzyskania pierwszego sukcesu, ma rozkład geometryczny.

Dla  $Y = X + 1$ ,  $E[Y] = \frac{1}{p}$ ,  $V(Y) = \frac{1-p}{p^2}$

#### Poisson, The Sequel

1. Istnieje  $\lambda > 0$ , że w dowolnie krótkim przedziale czasowym  $\Delta t$  prawdop. zaobserwowania dokładnie jednego zdarzenia wynosi  $\lambda \cdot \Delta t + o(\Delta t)$ . 2.Prawdop. zaobserwowania w  $\Delta t$  więcej niż jednego zdarzenia wynosi  $o(\Delta t)$ . 3. Liczba zaobserwowanych zd.los. w  $\Delta t$  jest niezależna od liczby wcześniej zaobserwowanych zdarzeń.

Jeśli 1-3 spełnione, to  $P_k(t)$ , że liczba zdarzeń zaobserwowanych do chwili  $t$  jest równa  $k$  wynosi  $P_k(t) = e^{-\lambda t} \frac{(\lambda t)^k}{k!}$ ,  $E[X] = \lambda = V(X)$

### Rozkłady zmiennych ciągłych

#### Jednostajny

$X$  ma rozkład jednostajny na  $[a, b]$ ,  $X \sim U(a, b)$  jeśli  $f(x) = \frac{1}{b-a}$  dla  $x \in [a, b]$  i 0 dla pozostałych. Dla  $x \in [a, b)$ ,  $F(x) = \frac{x-a}{b-a}$ .

$$E[X] = \frac{a+b}{2}, V(X) = \frac{(b-a)^2}{12}$$

#### Normalny

$$X \sim N(\mu, \sigma^2), f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right]$$

$F(x) = P(X \leq x) = \Phi(\frac{x-\mu}{\sigma})$ , gdzie  $\Phi$  patrz poniżej,  $E[X] = \mu$ ,  $V(X) = \sigma^2$

Jeśli  $X$  ma normalny, to  $Y = aX + b \sim N(a\mu + b, a^2\sigma^2)$

#### Standardowy normalny

$$U \sim N(0, 1), \text{ gęstość: } \phi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2},$$

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-t^2/2} dt.$$

#### Wykładniczy

Własność braku pamięci:  $P(X > s + t | X > t) = P(X > s)$

$X \sim \exp(\lambda)$ ,  $f(x) = \lambda e^{-\lambda x}$ ,  $x \geq 0$  i 0 gdy  $x < 0$ .  $F(x) = 1 - e^{-\lambda x}$ ,  $x \geq 0$ .

### Gamma

Gamma Eulera:  $\Gamma(\alpha) = \int_0^\infty x^{\alpha-1} e^{-x} dx$ ,  $\alpha > 0$ .

Własności: 1.  $\Gamma(\alpha + 1) = \alpha \cdot \Gamma(\alpha)$  2.  $\forall_{n \in N} \Gamma(n) = (n-1)!$  3.  $\forall_{x \in (0,1)} \Gamma(x) \Gamma(1-x) = \frac{\pi}{\sin(x\pi)}$   
 $X \sim \gamma(\alpha, \beta)$ ,  $f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}$  dla  $x \geq 0$  i 0 w p.p.

$$aX \sim \gamma(\alpha, \frac{\beta}{a}), E[X] = \frac{\alpha}{\beta}, V(X) = \frac{\alpha}{\beta^2}$$

### Zmienne losowe dwuwymiarowe

dystybuanta:  $F(x, y) = P(X \leq x, Y \leq y)$

Własności: 1.  $\lim_{x \rightarrow -\infty} F(x, y) = 0$ ,  $\lim_{y \rightarrow -\infty} F(x, y) = 0$ ,  $\lim_{x, y \rightarrow -\infty} F(x, y) = 1$ . 2. Niemalejąca ze względu na każdą ze zmiennych. 3. Prawostronnie ciągła ze względu na każdą ze zmiennych. 4.  $F(x_1, y_1) + F(x_2, y_2) - F(x_1, y_2) - F(x_2, y_1) \geq 0$

#### Dyskretne

funkcja prawdop.  $p(x, y) = P(X = x, Y = y)$

Własności: 1.  $p(x, y) \geq 0$  2.  $\sum_x \sum_y p(x, y) = 1$

Rozkłady brzegowe X:  $p_X(x) = P(X = x) = \sum_{y \in Y} p(x, y)$ , y analogicznie

Zmienne  $X$  i  $Y$  są niezależne, gdy  $p(x, y) = p_X(x) \cdot p_Y(y)$  **Ciągłe**

$f$  gęstość, jeśli:  $P\{(X, Y) \in A\} = \iint_A f(x, y) dx dy$

$$f(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv$$

$$f(x, y) \geq 0, \iint_{R^2} f(x, y) dx dy = 1$$

Gęstości brzegowe X:  $f_X(x) = \int_{-\infty}^\infty f(x, y) dy$ , y analogicznie

Zmienne  $X$  i  $Y$  są niezależne, gdy  $F(x, y) = F_X(x) \cdot F_Y(y)$ , co jest równoważne  $f(x, y) = f_X(x) \cdot f_Y(y)$

### Funkcje zmiennych losowych

Dyskretne:

Jeśli  $X_1, \dots, X_n$  - niezależnie zmienne o jednakowych rozkładach Bernoulliego, to  $S_n = \sum_{i=1}^n X_i \sim b(n, p)$

Jeśli  $X_i \sim b(n_i, p)$ , to  $\sum_{i=1}^n \sim b(\sum_{i=1}^n n_i, p)$ .

Jeśli  $X_i \sim P(\lambda_i)$ , to  $\sim_{i=1}^n X_i \sim P(\sum_{i=1}^n \lambda_i)$

Ciągłe:

Niech  $Z = g(X, Y)$ . Dystybuanta  $F_Z(z) =$

$$P(Z \leq z) = \iint_{\{(x,y):g(x,y)\leq z\}} f(x,y) dx dy$$

Gęstość sumy  $Z = X + Y$  :  $f_Z(z) = \int_{-\infty}^\infty f(x, z-x) dx$ , gdy  $X$  i  $Y$  niezależne, to  $f_{X+Y}(z) = \int_{-\infty}^\infty f_X(x) f_Y(z-x) dx$

Jeśli  $X_i \sim N(\mu_i, \sigma_i^2)$  (niezależne), to  $\sum_{i=1}^n \sim N(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2)$

Jeśli  $X_i \sim \gamma(\alpha_i, \beta)$ , to  $\sum_{i=1}^n X_i \sim \gamma(\sum_i \alpha_i, \beta)$   
 $E[h(X, Y)] = \sum_x \sum_y h(x, y) p(x, y)$  dla dyskretnych,  $= \int_{-\infty}^\infty \int_{-\infty}^\infty h(x, y) f(x, y) dx dy$   
 $E[aX + bY] = aE[X] + bE[Y]$ ,  $V(aX + bY) = a^2V(X) + b^2V(Y) + 2ab\text{Cov}(X, Y)$

$\text{Cov}(X, Y) = E(X, Y) - E(X)E(Y)$

Współczynnik korelacji:  $\rho_{X,Y} = \frac{\text{Cov}(X,Y)}{\sigma_x \cdot \sigma_y}$

### Regresja liniowa

Jeśli  $(X, Y)$  dwuwymiarowa zmienna losowa, dla której istnieją  $\sigma_X^2, \sigma_Y^2$  oraz Cov, to  $E\{[Y - (aX + b)]^2\}$  osiąga minimum gdy  $a = \rho_{XY} \frac{\sigma_Y}{\sigma_X}$  oraz  $b = m_Y - am_X$  tzn. funkcja regresji zmiennej  $Y$  przy  $X = x$  jest równa  $\frac{y-m_Y}{\sigma_Y} = \rho_{XY} \frac{x-m_X}{\sigma_X}$