

Zdarzenie elementarne

Każdy możliwy wynik eksperymentu losowego nazywamy **zdarzeniem elementarnym** ω , a zbiór wszystkich możliwych wyników eksperymentu (wszystkich zdarzeń elementarnych) nazywamy **zbiorem zdarzeń elementarnych** i oznaczamy $\Omega, (\omega \in \Omega)$.

Aksjomaty prawdopodobieństwa

Dla danego zbioru zdarzeń elementarnych Ω oraz σ -ciała zdarzeń losowych \mathcal{F} , **prawdopodobieństwem** nazywamy funkcję $P: \mathcal{F} \rightarrow \mathcal{R}$ spełniającą:

1. Dla dowolnego zdarzenia losowego $A \in \mathcal{F}$, $P(A) \geq 0$.
2. $P(\Omega) = 1$.
3. Dla dowolnego nieskończonego ciągu zdarzeń losowych $A_1, A_2, \dots, \forall n \in \mathcal{N} A_n \in \mathcal{F}$, parami rozłącznych, mamy $P(\bigcup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} P(A_n)$.

Dla dowolnych zdarzeń A, B mamy

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

Prawdopodobieństwo warunkowe

Prawdopodobieństwo A pod warunkiem że zaszło zdarzenie B : $P(A|B) = \frac{P(A \cap B)}{P(B)}$.

Jeżeli $P(A_1 \cap \dots \cap A_n) > 0$, to $P(A_1 \cap \dots \cap A_n) = P(A_1) \prod_{i=2}^n P(A_i | A_1 \cap \dots \cap A_{i-1})$.

Prawdopodobieństwo zupełne

Ciąg zdarzeń nazywamy zupełnym, jeśli:

1. $\bigcup_i A_i = \Omega$,
2. $\forall i \neq j A_i \cap A_j = \emptyset$,
3. $\forall_i P(A_i) > 0$.

Twierdzenie

Jeśli zdarzenia tworzą układ zupełny, to dla dowolnego zdarzenia B mamy $P(B) = \sum_i P(B|A_i)P(A_i)$

Reguła Bayesa

Twierdzenie Niech A_i tworzą układ zupełny. Wtedy dla dowolnego zdarzenia losowego $B, P(B) > 0$ i dowolnego j zachodzi

$$P(A_j|B) = \frac{P(B|A_j)P(A_j)}{\sum_i P(B|A_i)P(A_i)}$$

Niezależność zdarzeń

Definicja Zdarzenia są wzajemnie niezależne gdy $P(A \cap B) = P(A) \cdot P(B)$

Jeżeli zdarzenia A i B są niezależne, to niezależne są również zdarzenia A i \bar{B} , \bar{A} i B , \bar{A} i \bar{B} .

Zdarzenia są wzajemnie niezależne jeśli $P\left(\bigcap_{j=1}^k A_{i_j}\right) = \prod_{j=1}^k P(A_{i_j})$.

Jeśli $A_1 \dots$ są zdarzeniami wzajemnie niezależnymi, to $P(\bigcup_{i=1}^n A_i) = 1 - \prod_{i=1}^n (1 - P(A_i))$

Łączenie prawdopodobieństw

szeregowo: $P(A_s) = \prod_{i=1}^n p_i$
równoległe: $P(A_r) = 1 - \prod_{i=1}^n (1 - p_i)$

Dystrybuanta

$$F(x) = P(X \leq x) = P(\{\omega \in \Omega : X(\omega) \leq x\})$$

Własności:

$$\lim_{x \rightarrow -\infty} F(x) = 0, \lim_{x \rightarrow \infty} F(x) = 1$$

niemalejąca, prawostronnie ciągła.

$$P(a < X \leq b) = F(b) - F(a)$$

Zmienne losowe dyskretne

$p(a) = P(X = a)$ - funkcja prawdopodobieństwa, własności:

$$p(x) \geq 0, \sum_{x \in X} p(x) = 1$$

Dystrybuanta dyskretnej zmiennej X o nośniku χ : $F(x) = \sum_{\{x_i \in \chi: x_i \leq x\}} p(x_i)$.

Przykład:

$$F(x) = \begin{cases} 0, & x < 1 \\ 0.4, & 1 \leq x < 2 \\ 1, & x \geq 2 \end{cases}$$

Zmienne losowe ciągłe

$$P(X \in B) = \int_B f(x) dx$$

$$F(x) = \int_{-\infty}^x f(t) dt$$

$$f(x) = F'(x)$$

$$P(a \leq X \leq b) = F(b) - F(a)$$

$$P(X = a) = 0 \text{ dla dowolnego } a \in R$$

Własności funkcji gęstości:

$$\forall x \in R f(x) \geq 0, \int_{-\infty}^{+\infty} f(x) dx = 1$$

Funkcje zmiennych losowych

Dyskretne:

$$P(Y = y_i) = \sum_{\{x_j \in \chi: g(x_j) = y_i\}} P(X = x_j)$$

Ciągłe: gęstość liniowej funkcji zm.los.

$$\forall a \neq 0 b \in R f_{aX+b}(y) = \frac{1}{|a|} f_X\left(\frac{y-b}{a}\right)$$

gęstość kwadratu zm.los.

$$f_{X^2}(y) = \begin{cases} 0, & x \leq 0 \\ \frac{1}{2\sqrt{y}} [f_X(\sqrt{y}) + f_X(-\sqrt{y})], & x > 0 \end{cases}$$

Jeśli g jest ściśle monotoniczna i różniczkowalna, to $Y = g(X)$: $f_Y(y) = f_X(g^{-1}(y)) \cdot \frac{1}{|g'(g^{-1}(y))|}$

Wartość oczekiwana

Dyskretne: $E[X] = \sum_{x_i \in X} x_i \cdot P(X = x_i)$

Ciągłe: $E[X] = \int_{-\infty}^{+\infty} x f(x) dx$

Dla typu mieszanego o $F(x) = pF_d(x) + (1-p)F_c(x)$, $E[X] = pE[X_d] + (1-p)E[X_c]$.

Dla funkcji zmiennej losowej $Y = g(X)$:

$$E[g(X)] = \sum_i g(x_i)P(X = x_i) \text{ jeśli } X \text{ jest zm.los. dyskretną, } E[g(X)] = \int_{-\infty}^{+\infty} g(x)f_X(x)dx, \text{ jeśli } X \text{ jest zm.los. ciągłą.}$$

$$E[g(X)] = \sum_i g(x_i)P(X = x_i) \text{ jeśli } X \text{ jest zm.los. dyskretną, } E[g(X)] = \int_{-\infty}^{+\infty} g(x)f_X(x)dx, \text{ jeśli } X \text{ jest zm.los. ciągłą.}$$

Jeśli istnieje wartość oczekiwana $E[X]$, to $E[aX + b] = aE[X] + b$

$$E[aX + b] = aE[X] + b$$

Momenty

Momentem rzędu n -tego względem $c \in R$ zmiennej losowej X nazywamy: $E[(X-c)^n]$

Momenty zwykłe: $c = 0$

Pierwszy moment: $E[X]$

Jeśli istnieje n -ty moment zwykły, to istnieją wszystkie momenty rzędu mniejszego od n

Momenty centralne: $c = E[X]$

$$\text{Wariancja: } V(X) = \sigma_x^2 = \sigma^2 = E[(X - \mu)^2] = E[X^2] - (E[X])^2, \text{ gdzie } \mu = E[X]$$

$$V(aX + b) = V(aX) = a^2 V(X)$$

Odchylenie standardowe: $\sigma = \sqrt{V(X)}$

Zmienna X jest standaryzowana jeśli $E[X] = 0$ i $V(X) = 1$

$$\text{Standaryzacja: } X^* = \frac{X - \mu}{\sigma}$$

Współczynnik skośności:

$$\gamma_1 = E\left[\left(\frac{X - \mu}{\sigma}\right)^3\right] = \frac{\mu_3}{\sigma^3} = \frac{E[(X - \mu)^3]}{(E[(X - \mu)^2])^{3/2}}$$

$$\text{Kurtioza: } \gamma_2 = \frac{\mu_4}{\sigma^4} - 3$$

Kwantyle, kwartyle

Kwantyl: $\forall p \in (0,1) x_p = Q(p) = F^{-1}(p) = \inf\{x \in R : p \leq F(x)\}$

Mediana: kwantyl $x_{0.5}$ rzędu 0.5.

Dolny kwantyl Q_1 - kwantyl rzędu 0.25,

górny kwantyl Q_3 - kwantyl rzędu 0.75

Rozkład międzykwartylowy $IQR = Q_3 - Q_1$

Doświadczenie Bernoulliego

Doświadczenie kończące się sukcesem z prawdopodobieństwem p lub porażką z prawdopodobieństwem $1-p$.

Ciąg n doświadczeń z prawd. sukcesu p oznaczamy $b(n, p)$.

Prawdopodobieństwo uzyskania ciągu składającego się z k sukcesów, przy założeniu niezależności: $p^k(1-p)^{n-k}$.

Prawdopodobieństwo uzyskania k sukcesów w n niezależnych doświadczeniach z $p \in [0, 1]$: $b(k; n, p) = \binom{n}{k} p^k (1-p)^{n-k}$.

Poisson (fr. Ryba)

Dla $n \geq 25$ i $\lambda = n \cdot p \leq 10$ możemy przybliżyć rozkładem Poissona: $b(k; n, p) \approx e^{-np} \cdot \frac{(np)^k}{k!}$, na przykład:

$$\sum_{k=0}^{14} b(k; 500, 0.02) \approx F(14; 500 \cdot 0.02),$$

gdzie F jest dystrybuantą rozkładu Ryby, dostępną w tablicach.

Rozkłady zmiennych dyskretnych

Bernoulli

1. Eksperyment składa się z n mniejszych doświadczeń, zwanych próbami, gdzie n jest ustalone i znane przed doświadczeniem.

2. Każda próba kończy się sukcesem lub porażką.

3. Próby są niezależne.

X ma rozkład Bernoulliego jeśli

$$p(x) = P(X = x) = \begin{cases} 1 - p, & x = 0 \\ p, & x = 1 \end{cases}$$

$$E[X] = p, V(X) = p(1-p)$$

Dwumianowy, czyli dalej Bernoulli

Zmienną losową X równą liczbie sukcesów w n niezależnych doświadczeniach Bernoulliego nazywamy zmienną o rozkładzie dwumianowym z param. (n, p) , oznaczamy $X \sim b(n, p)$.

$$P(X = k) = b(k; n, p) = \binom{n}{k} p^k (1-p)^{n-k}$$

$$E[X] = np, V(X) = np(1-p)$$

Hipergeometryczny

1. Losujemy ze zbioru N elementów. 2. Każdemu z N obiektów można przypisać sukces lub porażka (mamy M sukcesów). 3. Wybieramy n obiektów bez zwracania tak, że wybór każdego n elementowego podzbioru ma to samo prawdopodobieństwo.

Liczba sukcesów X ma rozkład hipergeometryczny $X \sim HG(n, M, N)$ $P(X = x) = h(x; n, M, N) = \frac{\binom{M}{x} \binom{N-M}{n-x}}{\binom{N}{n}}$, $E[X] = \frac{nM}{N}$, $V(X) = \left(\frac{N-n}{N-1}\right) \frac{nM}{N} \left(1 - \frac{M}{N}\right)$

Ujemny dwumianowy (Pascala)

1. Niezależne próby Bernoulliego. 2. Eksperyment kończy się w chwili uzyskania r -tego sukcesu, r ustalone.

X - Liczba porażek do uzyskania r -tego sukcesu ma rozkład ujemny dwumianowy $X \sim NB(r, p)$, $nb(x; r, p) = \binom{x+r-1}{r-1} p^r (1-p)^x$, $E[X] = \frac{r(1-p)}{p}$, $V(X) = \frac{r(1-p)}{p^2}$

Geometryczny

X równa liczbie porażek w ciągu niezależnych doświadczeń Bernoulliego, do uzyskania pierwszego sukcesu, ma rozkład geometryczny.

$$\text{Dla } Y = X + 1, E[Y] = \frac{1}{p}, V(Y) = \frac{1-p}{p^2}$$

Poisson, The Sequel

1. Istnieje $\lambda > 0$, że w dowolnie krótkim przedziale czasowym Δt prawdop. zaobserwowania dokładnie jednego zdarzenia wynosi $\lambda \cdot \Delta t + o(\Delta t)$. 2. Prawdop. zaobserwowania w Δt więcej niż jednego zdarzenia wynosi $o(\Delta t)$. 3. Liczba zaobserwowanych zd. los. w Δt jest niezależna od liczby wcześniej zaobserwowanych zdarzeń.

Jeśli 1-3 spełnione, to $P_k(t)$, że liczba zdarzeń zaobserwowanych do chwili t jest równa

$$k \text{ wynosi } P_k(t) = e^{-\lambda t} \frac{(\lambda t)^k}{k!}, E[X] = \lambda = V(X)$$

Rozkłady zmiennych ciągłych

Jednostajny

X ma rozkład jednostajny na $[a, b]$, $X \sim U(a, b)$ jeśli $f(x) = \frac{1}{b-a}$ dla $x \in [a, b]$ i 0 dla pozostałych. Dla $x \in [a, b]$, $F(x) = \frac{x-a}{b-a}$, dla $x < a$ $F(x) = 0$, dla $x \geq b$ $F(x) = 1$

$$E[X] = \frac{a+b}{2}, V(X) = \frac{(b-a)^2}{12}$$

Normalny

$X \sim N(\mu, \sigma^2)$, $f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right]$
 $F(x) = P(X \leq x) = \Phi\left(\frac{x-\mu}{\sigma}\right)$, gdzie Φ patrz poniżej, $E[X] = \mu$, $V(X) = \sigma^2$

Jeśli X ma normalny, to $Y = aX + b \sim N(a\mu + b, a^2\sigma^2)$

Standardowy normalny

$U \sim N(0, 1)$, gęstość: $\phi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2}$,

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-t^2/2} dt.$$

Wykładniczy

Własność braku pamięci: $P(X > s + t | X > t) = P(X > s)$

$X \sim \exp(\lambda)$, $f(x) = \lambda e^{-\lambda x}$, $x \geq 0$ i 0 gdy $x < 0$. $F(x) = 1 - e^{-\lambda x}$, $x \geq 0$.

Gamma

Gamma Eulera:

$$\Gamma(\alpha) = \int_0^\infty x^{\alpha-1} e^{-x} dx, \alpha > 0$$

Własności:

- $\Gamma(\alpha + 1) = \alpha \cdot \Gamma(\alpha)$
- $\forall n \in \mathbb{N} \Gamma(n) = (n-1)!$
- $\forall x \in (0, 1) \Gamma(x) \Gamma(1-x) = \frac{\pi}{\sin(x\pi)}$

$X \sim \gamma(\alpha, \beta)$, $f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}$ dla $x \geq 0$ i 0 w p.p.

$$aX \sim \gamma(\alpha, \frac{\beta}{a}), E[X] = \frac{\alpha}{\beta}, V(X) = \frac{\alpha}{\beta^2}$$

Zmienne losowe dwuwymiarowe

dystrybuita: $F(x, y) = P(X \leq x, Y \leq y)$

Własności: 1. $\lim_{x \rightarrow -\infty} F(x, y) = 0$, $\lim_{y \rightarrow -\infty} F(x, y) = 0$, $\lim_{x, y \rightarrow \infty} F(x, y) = 1$.

2. Niemalejąca ze względu na każdą ze zmiennych.
3. Prawostronnie ciągła ze względu na każdą ze zmiennych.
4. $F(x_1, y_1) + F(x_2, y_2) - F(x_1, y_2) - F(x_2, y_1) \geq 0$

Dyskretne

funkcja prawdop. $p(x, y) = P(X = x, Y = y)$

Własności: 1. $p(x, y) \geq 0$ 2. $\sum_x \sum_y p(x, y) = 1$

Rozkłady brzegowe X : $p_X(x) = P(X = x) = \sum_{y \in Y} p(x, y)$, Y analogicznie

Zmienne X i Y są niezależne, gdy $p(x, y) = p_X(x) \cdot p_Y(y)$

Ciągłe

f gęstość, jeśli: $P\{(X, Y) \in A\} = \iint_A f(x, y) dx dy$

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv$$

$$f(x, y) \geq 0, \iint_{\mathbb{R}^2} f(x, y) dx dy = 1$$

Gęstości brzegowe X : $f_X(x) = \int_{-\infty}^\infty f(x, y) dy$, Y analogicznie

Zmienne X i Y są niezależne, gdy $F(x, y) = F_X(x) \cdot F_Y(y)$, co jest równoważne $f(x, y) = f_X(x) \cdot f_Y(y)$

Funkcje zmiennych losowych

Dyskretne:

Jeśli X_1, \dots, X_n - niezależne zmienne o jednakowych rozkładach Bernoulliego, to $S_n = \sum_{i=1}^n X_i \sim B(n, p)$, wtedy $P(S_n \leq s) = \sum_{k=0}^s \binom{n}{k} p^k (1-p)^{n-k}$

Jeśli $X_i \sim b(n_i, p)$, to $\sum_{i=1}^n X_i \sim b(\sum_{i=1}^n n_i, p)$.

Jeśli $X_i \sim P(\lambda_i)$, to $\sum_{i=1}^n X_i \sim P(\sum_{i=1}^n \lambda_i)$

Ciągłe:

Niech $Z = g(X, Y)$. Dystrybuita $F_Z(z) = P(Z \leq z) = \iint_{\{(x, y): g(x, y) \leq z\}} f(x, y) dx dy$

Gęstość sumy $Z = X + Y$: $f_Z(z) = \int_{-\infty}^\infty f(x, z-x) dx$, gdy X i Y niezależne,

to $f_{X+Y}(z) = \int_{-\infty}^\infty f_X(x) f_Y(z-x) dx$

Jeśli $X_i \sim N(\mu_i, \sigma_i^2)$ (niezależne), to $\sum_{i=1}^n X_i \sim N(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2)$

Jeśli $X_i \sim \gamma(\alpha_i, \beta)$, to $\sum_{i=1}^n X_i \sim \gamma(\sum_{i=1}^n \alpha_i, \beta)$

$$E[h(X, Y)] = \sum_x \sum_y h(x, y) p(x, y)$$

dla dyskretnych, $E[h(X, Y)] = \int_{-\infty}^\infty \int_{-\infty}^\infty h(x, y) f(x, y) dx dy$ dla ciągłych.

$$E[aX + bY] = aE[X] + bE[Y], V(aX + bY) = a^2V(X) + b^2V(Y) + 2ab\text{Cov}(X, Y)$$

$$\text{Cov}(X, Y) = E[XY] - E[X]E[Y]$$

$$\text{Współczynnik korelacji: } \rho_{X,Y} = \frac{\text{Cov}(X,Y)}{\sigma_X \cdot \sigma_Y}$$

Regresja liniowa

Jeśli (X, Y) dwuwymiarowa zmienna losowa, dla której istnieją σ_X^2 , σ_Y^2 oraz Cov , to $E\{[Y - (aX + b)]^2\}$ osiąga minimum gdy $a = \rho_{XY} \frac{\sigma_Y}{\sigma_X}$ oraz $b = m_Y - am_X$ tzn. funkcja regresji zmiennej Y przy $X = x$ jest równa $\frac{y - m_Y}{\sigma_Y} = \rho_{XY} \frac{x - m_X}{\sigma_X}$

Przybliżenie rozkładów

Przybliżenie normalne

$P(S_n \leq x) \approx \Phi\left(\frac{S_n - n\mu}{\sigma\sqrt{n}}\right)$, gdzie $E[x_i] = \mu$, $V(X_i) = \sigma^2$, $n \geq 50$

Rozkładu dwumianowego rozkładem normalnym

Jeśli $S_n \sim b(n, p)$, $n \geq 25$, $np \geq 5$, $n(1-p) \geq 5$, to $P(S_n \leq x) \approx \Phi\left(\frac{x+0.5-np}{\sqrt{np(1-p)}}\right)$

Rozkładu Poissona

$$F(k; \lambda) \approx \Phi\left(\frac{k+0.5-\lambda}{\sqrt{\lambda}}\right), \lambda > 10$$

Statystyka

Rozstęp $R = \max\{x_1, \dots, x_n\} - \min\{x_1, \dots, x_n\}$

Średnia:

dla danych nie pogrupowanych (naprawdę musisz to sprawdzać?)

dla danych pogrupowanych na k klas: $\bar{x} = \frac{1}{n} \sum_{j=1}^k n_j \bar{x}_j$

Wariancja: nie pogrupowane:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x}_n)^2$$

pogrupowane na k klas:

$$s^2 = \frac{1}{n-1} \sum_{j=1}^k n_j (\bar{x}_j - \bar{x}_n)^2$$