

Zdarzenie elementarne

Każdy możliwy wynik eksperymentu losowego nazywamy **zdarzeniem elementarnym** ω , a zbiór wszystkich możliwych wyników eksperymentu (wszystkich zdarzeń elementarnych) nazywamy **zbiorem zdarzeń elementarnych** i oznaczamy Ω , ($\omega \in \Omega$).

Aksjomaty prawdopodobieństwa

Dla danego zbioru zdarzeń elementarnych Ω oraz σ -ciała zdarzeń losowych \mathcal{F} , **prawdopodobieństwem** nazywamy funkcję $P: \mathcal{F} \rightarrow \mathcal{R}$ spełniającą:

1. Dla dowolnego zdarzenia losowego $A \in \mathcal{F}$, $P(A) \geq 0$.
2. $P(\Omega) = 1$.
3. Dla dowolnego nieskończonego ciągu zdarzeń losowych $A_1, A_2, \dots, \forall n \in \mathcal{N} A_n \in \mathcal{F}$, parami rozłącznych, mamy $P(\bigcup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} P(A_n)$.

Dla dowolnych zdarzeń A, B mamy $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.

Prawdopodobieństwo warunkowe

Prawdopodobieństwo A pod warunkiem że zaszło zdarzenie B : $P(A|B) = \frac{P(A \cap B)}{P(B)}$.

Jeżeli $P(A_1 \cap \dots \cap A_n) > 0$, to $P(A_1 \cap \dots \cap A_n) = P(A_1) \prod_{i=2}^n P(A_i | A_1 \cap \dots \cap A_{i-1})$.

Prawdopodobieństwo zupełne

Ciąg zdarzeń nazywamy zupełnym, jeśli:

1. $\bigcup_i A_i = \Omega$,
2. $\forall i \neq j A_i \cap A_j = \emptyset$,
3. $\forall_i P(A_i) > 0$.

Twierdzenie

Jeśli zdarzenia tworzą układ zupełny, to dla dowolnego zdarzenia B mamy $P(B) = \sum_i P(B|A_i)P(A_i)$

Reguła Bayesa

Twierdzenie Niech A_i tworzą układ zupełny. Wtedy dla dowolnego zdarzenia losowego B , $P(B) > 0$ i dowolnego j zachodzi $P(A_j|B) = \frac{P(B|A_j)P(A_j)}{\sum_i P(B|A_i)P(A_i)}$

Niezależność zdarzeń

Definicja Zdarzenia są wzajemnie niezależne gdy $P(A \cap B) = P(A) \cdot P(B)$

Jeżeli zdarzenia A i B są niezależne, to nieza-

leżne są również zdarzenia A i \overline{B} , \overline{A} i B , \overline{A} i \overline{B} .

Zdarzenia są wzajemnie niezależne jeśli $P(\bigcap_{j=1}^k A_{i_j}) = \prod_{j=1}^k P(A_{i_j})$.

Jeśli $A_1 \dots$ są zdarzeniami wzajemnie niezależnymi, to $(\bigcup_{i=1}^n A_i) = 1 - \prod_{i=1}^n (1 - P(A_i))$

Łączenie prawdopodobieństw

szeregowe: $P(A_s) = \prod_{i=1}^n p_i$
równoległe: $P(A_r) = 1 - \prod_{i=1}^n (1 - p_i)$

Dystrybuanta

$F(x) = P(X \leq x) = P(\{\omega \in \Omega : X(\omega) \leq x\})$

Własności:

$\lim_{x \rightarrow -\infty} F(x) = 0$, $\lim_{x \rightarrow \infty} F(x) = 1$

niemalejąca, prawostronnie ciągła

$P(a < X \leq b) = F(b) - F(a)$

Zmienne losowe dyskretne

$p(a) = P(X = a)$ - funkcja prawdopodobieństwa, własności:

$p(x) \geq 0$, $\sum_{x \in X} p(x) = 1$

Dystrybuanta dyskretna zmiennej X o nośniku χ : $F(x) = \sum_{\{x_i \in \chi; x_i \leq x\}} p(x_i)$.

Przykład:

$$F(x) = \begin{cases} 0, & x < 1 \\ 0.4, & 1 \leq x < 2 \\ 0.9, & 2 \leq x \end{cases}$$

Zmienne losowe ciągłe

$P(X \in B) = \int_B f(x) dx$

$F(x) = \int_{-\infty}^x f(t) dt$

$f(x) = F'(x)$

$P(a \leq X \leq b) = F(b) - F(a)$

$P(X = a) = 0$ dla dowolnego $a \in R$

Własności funkcji gęstości:

$\forall x \in R f(x) \geq 0$, $\int_{-\infty}^{+\infty} f(x) dx = 1$

Funkcje zmiennych losowych

Dyskretne:

$P(Y = y_i) = \sum_{\{x_j \in \chi: g(x_j) = y_i\}} P(X = x_j)$

Ciągłe: gęstość liniowej funkcji zm.los.

$\forall a \neq 0 b \in R f_{aX+b}(y) = \frac{1}{|a|} f_X\left(\frac{y-b}{a}\right)$

gęstość kwadratu zm.los.

$$f_{X^2}(y) = \begin{cases} 0, & x \leq 0 \\ \frac{1}{2\sqrt{y}} [f_X(\sqrt{y}) + f_X(-\sqrt{y})], & x > 0 \end{cases}$$

Jeśli g jest ściśle monotoniczna i różniczkowalna, to $Y = g(X)$: $f_Y(y) = f_X(g^{-1}(y)) \cdot \frac{1}{|g'(g^{-1}(y))|}$

Wartość oczekiwana

Dyskretne: $E[X] = \sum_{x_i \in X} x_i \cdot P(X = x_i)$

Ciągłe: $E[X] = \int_{-\infty}^{+\infty} x f(x) dx$

Dla typu mieszanego o $F(x) = pF_d(x) + (1-p)F_c(x)$, $E[X] = pE[X_d] + (1-p)E[X_c]$.

Dla funkcji zmiennej losowej $Y = g(X)$:

$$E[g(X)] = \begin{cases} \sum_i g(x_i) P(X = x_i), & \text{jeśli } X \text{ jest zm.los. dyskretna} \\ \int_{-\infty}^{+\infty} g(x) f_X(x) dx, & \text{jeśli } X \text{ jest zm.los. ciągła} \end{cases}$$

Jeśli istnieje wartość oczekiwana $E[X]$, to

$E[aX + b] = aE[X] + b$

Momenty

Momentem rzędu n -tego względem $c \in R$ zmiennej losowej X nazywamy: $E[(X - c)^n]$

Momenty zwykłe: $c = 0$

Pierwszy moment: $E[X]$

Jeśli istnieje n -ty moment zwykły, to istnieją wszystkie momenty rzędu mniejszego od n

Momenty centralne: $c = E[X]$

Wariancja: $V(X) = \sigma_x^2 = \sigma^2 = E[(X - \mu)^2] = E[X^2] - (E[X])^2$, gdzie $\mu = E[X]$

$V(aX + b) = V(aX) = a^2 V(X)$

Odchylenie standardowe: $\sigma = \sqrt{V(X)}$

Zmienna X jest standaryzowana jeśli $E[X] = 0$ i $V(X) = 1$

Standaryzacja: $X^* = \frac{X - \mu}{\sigma}$

Współczynnik skośności: $\gamma_1 = E\left[\left(\frac{X - \mu}{\sigma}\right)^3\right] = \frac{E[(X - \mu)^3]}{(E[(X - \mu)^2])^{3/2}}$

Kurtosis: $\gamma_2 = \frac{\mu_4}{\sigma^4} - 3$

Kwantyle, kwartyle

Kwantyl: $\forall p \in (0,1) x_p = Q(p) = F^{-1}(p) = \inf\{x \in R : p \leq F(x)\}$

Mediana: kwantyl $x_{0.5}$ rzędu 0.5.

Dolny kwantyl Q_1 - kwantyl rzędu 0.25, górny kwantyl Q_3 - kwantyl rzędu 0.75

Rozkład międzykwartylowy $IQR = Q_3 - Q_1$

Doświadczenie Bernoulliego

Doświadczenie kończące się sukcesem z prawdopodobieństwem p lub porażką z prawdopodobieństwem $1-p$.

Ciąg n doświadczeń z prawd. sukcesu p oznaczamy $b(n, p)$.

Prawdopodobieństwo uzyskania ciągu składającego się z k sukcesów, przy założeniu niezależności: $p^k (1 - p)^{n-k}$.

Prawdopodobieństwo uzyskania k sukcesów w n niezależnych doświadczeniach z $p \in [0, 1]$: $b(k; n, p) = \binom{n}{k} p^k (1 - p)^{n-k}$.

Poisson (fr. Ryba)

Dla $n \geq 25$ i $\lambda = n \cdot p \leq 10$ możemy przybliżyć rozkładem Poissona: $b(k; n, p) \approx e^{-np} \frac{(np)^k}{k!}$, na przykład: $\sum_{k=0}^{14} b(k; 500, 0.02) \approx F(14; 500 \cdot 0.02)$, gdzie F jest dystrybuantą rozkładu Ryby, dostępna w tablicach.

Rozkłady zmiennych dyskretnych Bernoulli

1. Eksperyment składa się z n mniejszych doświadczeń, zwanych próbami, gdzie n jest ustalone i znane przed doświadczeniem.
2. Każda próba kończy się sukcesem lub porażką.
3. Próby są niezależne.

X ma rozkład Bernoulliego jeśli

$$p(x) = P(X = x) = \begin{cases} 1 - p, & x = 0 \\ p, & x = 1 \end{cases}$$

$E[X] = p$, $V(X) = p(1 - p)$

Dwumianowy, czyli dalej Bernoulli

Zmienną losową X równą liczbie sukcesów w n niezależnych doświadczeniach Bernoulliego nazywamy zmienną o rozkładzie dwumianowym z param. (n, p) , oznaczamy $X \sim b(n, p)$. $P(X = k) = b(k; n, p) = \binom{n}{k} p^k (1 - p)^{n-k}$
 $E[X] = np$, $V(X) = np(1 - p)$

Hipergeometryczny

1. Losujemy ze zbioru N elementów.
2. Każdemu z N obiektów można przypisać sukces lub porażka (mamy M sukcesów).
3. Wybieramy n obiektów bez zwracania tak, że wybór każdego n elementowego podzbiotu ma to samo prawdopodobieństwo.

Liczba sukcesów X ma rozkład hipergeometryczny $X \sim HG(n, M, N)$, $P(X = x) = h(x; n, M, N) = \frac{\binom{M}{x} \binom{N-M}{n-x}}{\binom{N}{n}}$, $E[X] =$

$$\frac{nM}{N}, V(X) = \binom{\frac{N-n}{N-1}}{\frac{nM}{N}} \left(1 - \frac{M}{N}\right)$$

Ujemny dwumianowy (Pascala)

1. Niezależne próby Bernoulliego. 2. Eksperyment kończy się w chwili uzyskania r -tego sukcesu, r ustalone.

X - Liczba porażek do uzyskania r -tego sukcesu ma rozkład ujemny dwumianowy
 $X \sim NB(r, p)$, $nb(x; r, p) = \binom{x+r-1}{r-1} p^r (1-p)^x$, $E[X] = \frac{r(1-p)}{p}$, $V(X) = \frac{r(1-p)}{p^2}$

Geometryczny

X równa liczbie porażek w ciągu niezależnych doświadczeń Bernoulliego, do uzyskania pierwszego sukcesu, ma rozkład geometryczny.

Dla $Y = X + 1$, $E[Y] = \frac{1}{p}$, $V(Y) = \frac{1-p}{p^2}$

Poisson, The Sequel

1. Istnieje $\lambda > 0$, że w dowolnie krótkim przedziale czasowym Δt prawdop. zaobserwowania dokładnie jednego zdarzenia wynosi $\lambda \cdot \Delta t + o(\Delta t)$. 2. Prawdop. zaobserwowania w Δt więcej niż jednego zdarzenia wynosi $o(\Delta t)$. 3. Liczba zaobserwowanych zd.los. w Δt jest niezależna od liczby wcześniej zaobserwowanych zdarzeń.

Jeśli 1-3 spełnione, to $P_k(t)$, że liczba zdarzeń zaobserwowanych do chwili t jest równa k wynosi $P_k(t) = e^{-\lambda t} \frac{(\lambda t)^k}{k!}$, $E[X] = \lambda = V(X)$